Xử lý **Dữ liệu thời gian không đều (Irregular Time Series)** mang đặc tính **Thiếu hụt có chủ đích (Informative Missingness)**.

**1. Kỹ thuật Imputation (Điền khuyết dữ liệu)**

**- Nội suy toán học (Interpolation):** Dùng Linear (tuyến tính) hoặc Spline (đường cong). Cách này giữ được xu hướng (trend) của tiểu cầu. Tuy nhiên, nó chỉ tốt nếu khoảng trống ngắn (ví dụ thiếu 1 ngày). Nếu thiếu ngày 2, 3, 4, đường nội suy có thể tạo ra "ảo giác" về sự ổn định.

**- MICE (Multiple Imputation by Chained Equations):** Thay vì chỉ nhìn vào chuỗi thời gian của riêng tiểu cầu, MICE sử dụng các *features khác* trong cùng ngày (như hồng cầu, bạch cầu, huyết áp, nhiệt độ) để học ra một mô hình hồi quy và điền vào giá trị tiểu cầu bị thiếu.

**- Deep Learning Imputation (BRITS & GAIN) - BRITS (Bidirectional Recurrent Imputation for Time Series):** Chạy hai mạng RNN theo hai chiều (từ ngày 1 đến 5 và từ 5 về 1) để dự đoán giá trị ở giữa, đồng thời mô hình hóa luôn sự tương quan giữa các biến số. **GAIN:** Sử dụng kiến trúc GAN (Generative Adversarial Networks). Generator cố gắng tạo ra các giá trị tiểu cầu giả để điền vào chỗ trống, còn Discriminator cố gắng phân biệt đâu là giá trị đo thật, đâu là do AI tạo ra.

**2. Sự vắng mặt của dữ liệu như một "Dấu hiệu lâm sàng"**

Trong y tế, dữ liệu thường thuộc dạng **MNAR (Missing Not At Random - Thiếu không ngẫu nhiên)**. Việc bác sĩ *không* chỉ định xét nghiệm tiểu cầu vào ngày 2 và 3 có thể mang thông điệp: *"Bệnh nhân đang đáp ứng thuốc tốt, không cần lấy thêm máu"*. Ngược lại, nếu bị xét nghiệm liên tục, đó có thể là dấu hiệu tiên lượng xấu.

Để AI học được điều này, cách tiếp cận **Masking & Time Delta** => mở rộng nó thành một vector 3 chiều cho mỗi ngày:

Xt: Giá trị tiểu cầu (nếu thiếu, có thể điền 0 hoặc nội suy).

Mt ∈{0, 1}: Biến Mask chỉ định dữ liệu là thật (1) hay điền khuyết (0).

Δt - Delta t: Thời gian trôi qua kể từ lần đo cuối cùng có dữ liệu thực (Time decay).

**3. Thiết kế Cấu trúc  giải quyết Irregular Time Series**

Nếu không nội suy mà muốn mô hình *tự tiêu hóa* dữ liệu thô nhiều NaN, tham khảo các lựa chọn sau:

- **Tree-based Models (XGBoost / LightGBM):** Sử dụng kỹ thuật *Sparsity-aware Split*, tự động học được hướng rẽ tối ưu trên cây quyết định khi gặp giá trị NaN mà không cần bạn phải điền bất kỳ số nào.
- **GRU-D (Gated Recurrent Unit with Decay):** Kiến trúc này đưa trực tiếp $\Delta t$ vào các cổng tính toán của nơ-ron. Cụ thể, khi thời gian $\Delta t$ càng lớn (tức là khoảng cách xét nghiệm càng xa), ảnh hưởng của giá trị tiểu cầu trước đó lên trạng thái hiện tại sẽ bị "phai mờ" (decay) dần về giá trị trung bình của quần thể.
- **Time-Aware Transformers:** Thay vì dùng *Positional Encoding* theo các bước tuần tự (1, 2, 3, 4, 5) như trong ngôn ngữ tự nhiên => thiết kế *Time Encoding* dựa trên thời điểm xét nghiệm thực tế (ví dụ: giờ thứ 0, giờ thứ 48, giờ thứ 96). Attention mechanism sẽ tự động tính toán trọng số giữa các mốc thời gian rời rạc này.
- **Neural ODEs (Ordinary Differential Equations):** kỹ thuật xem sự biến thiên của tiểu cầu là một quá trình liên tục được định nghĩa bằng phương trình vi phân. Nó có thể dự đoán trạng thái bệnh nhân tại *bất kỳ thời điểm nào*, phù hợp cho dữ liệu thu thập không theo chu kỳ.

=>

**Baseline (Dễ nhất):** Thêm 2 features Mask và Time_Delta, giữ nguyên NaN và đưa thẳng vào **XGBoost/LightGBM**.

**Advanced (Tối ưu chuỗi):** Điền khuyết bằng Nội suy Linear + Thêm Mask/Time_Delta, sau đó đưa vào **LSTM** hoặc **GRU**.

**State-of-the-art (Nghiên cứu sâu):** Cài đặt **GRU-D** hoặc **BRITS** để mô hình hóa trực tiếp sự suy giảm thông tin theo thời gian.